ENTREGABLE 3

Solución Final

Contexto, datos, proceso ETL, resultados y reflexiones finales

Pipeline ETL para Soft Sensor

Proceso de Aireación — Planta de Tratamiento de Aguas Residuales

Curso de ETL y Ciencia de Datos — Semestre 2026-1

Repositorio en GitHub · https://github.com/franciscopedroza030595/wwtp-soft-sensor-etl.git

1. Contexto

El tratamiento de aguas residuales constituye un proceso industrial de alta complejidad que involucra reacciones biológicas no lineales, variabilidad estocástica en la carga orgánica del influente y múltiples interdependencias entre variables operativas. Dentro de este sistema, el proceso de aireación representa la operación unitaria más demandante en términos energéticos — consumiendo entre el 40% y el 60% de la energía total de la planta — y la de mayor impacto directo sobre la calidad del efluente (Olsson et al., 2014).

La operación eficiente del proceso de aireación depende del monitoreo en tiempo real de variables críticas como el oxígeno disuelto (DO), el nitrógeno amoniacal (NH_3), el pH, los sólidos suspendidos (SS) y la temperatura. Sin embargo, los sensores físicos (hardware sensors) que capturan estas variables están sujetos a degradación por bioincrustación, deriva instrumental, fallos mecánicos y altos costos de calibración y mantenimiento. Haimi et al. (2013) señalan que la confiabilidad de los datos de sensores en plantas WWTP es un desafío persistente que limita la implementación de estrategias avanzadas de control.

En este contexto, los sensores por software (soft sensors) emergen como una alternativa complementaria. Un soft sensor es un modelo predictivo basado en datos que utiliza variables fácilmente medibles (presión, flujos de aire, temperatura del cabezal) como entradas para estimar variables difíciles o costosas de medir (amoniaco en el efluente, sólidos suspendidos). Chen et al. (2026) demostraron que un framework de LSTM adaptativo mejoró la correlación promedio de predicción en un 52.7% y redujo el error en un 62.1% respecto a modelos individuales, validando la viabilidad de estos enfoques en plantas reales.

No obstante, la construcción de cualquier modelo predictivo confiable requiere como paso previo un proceso riguroso de extracción, transformación y carga (ETL) de los datos. Los datos de sistemas SCADA industriales, aunque volumétricamente abundantes, presentan problemas de calidad que incluyen sensores inactivos, convenciones de señal no documentadas, gaps temporales y valores fuera de rango. Sin un ETL robusto, los modelos se entrenarían con datos incorrectos, produciendo predicciones no confiables.

Este proyecto desarrolla un pipeline ETL completo, reproducible y documentado que transforma los datos históricos del proceso de aireación de una WWTP real, dejándolos preparados para su uso posterior en tareas de ciencia de datos e inteligencia artificial. El alcance del presente trabajo comprende exclusivamente el proceso ETL; la implementación de modelos predictivos se plantea como trabajo futuro.

2. Datos

2.1 Fuente y formato

Los datos fueron exportados de la base de datos SQL del sistema SCADA (Supervisory Control and Data Acquisition) de una planta de tratamiento de aguas residuales ubicada en Carolina del Norte, Estados Unidos. El archivo fuente es un CSV con valores ya expresados en unidades de ingeniería reales, lo cual elimina la necesidad de factores de conversión o escalamiento.

Característica	Valor
Archivo	AmmoniaModelDataWitB1C7AmmoniumHuman.csv
Registros	105,409 filas × 31 columnas
Frecuencia de muestreo	1 registro cada 5 minutos (288/día)
Período	1 de noviembre de 2023 al 1 de noviembre de 2024
Duración	366 días (año bisiesto)
Tipos de datos	float64 e int64 (sin tipos mixtos)
Valores nulos nativos	1,456 (0.045% del total de celdas)
Tamaño	35.33 MB
Unidades	mg/L, PSI, SCFM, GPM, MGD, °F, °C

2.2 Categorización de variables

Las 31 variables del dataset se organizan en las siguientes categorías funcionales según su rol en el proceso de aireación:

- Variables de calidad del influente (1): Nitrógeno amoniacal en la estructura de distribución de flujo (media 43.18 mg/L). Representa la carga orgánica que ingresa al proceso biológico.
- Variables de oxígeno disuelto (6): DO medido en la celda 5 de cada uno de los 6 basins de aireación. El Basin 6 presenta un sensor completamente inactivo (99.9% ceros). Los 5 basins activos registran promedios entre 1.92 y 2.90 mg/L, consistentes con procesos de nitrificación.
- Variables de flujo de aire (12): Flujo de aire en SCFM para las celdas 1-6 y 7-10 de cada basin. Los flujos a celdas 1-6 presentan valores negativos por convención de señal del SCADA, particularmente en Basin 6 (89.1%) y Basin 4 (30.7%).
- Variables de flujo de proceso (3): Flujo influente total (~18 MGD), retorno de lodos activados RAS (~3,290 GPM) y licor mezclado recirculado MLR (~38 MGD).
- Variables de calidad del efluente (5): Nitrógeno amoniacal, fosfato, sólidos suspendidos, temperatura y pH del canal de efluente. Estas son las variables candidatas a ser estimadas por soft sensors.
- Variables operativas (2): Presión (~9 PSI) y temperatura (~170°F) del cabezal de aire comprimido.
- Variables intermedias (1): Nitrógeno amoniacal en Basin 1 Celda 7, que captura el estado del proceso en un punto intermedio del tratamiento.
- Timestamp (1): Marca temporal con formato MM/DD/YYYY HH:MM cada 5 minutos.

2.3 Autorización y citación

Los datos fueron proporcionados por la compañía operadora de la planta en el marco de un proyecto de mejora operativa del área SCADA. La información sensible (nombre comercial y dirección exacta de la planta) ha sido omitida para proteger la confidencialidad. Los datos procesados serán publicados en un repositorio compartido para garantizar la reproducibilidad del proyecto, acompañados de las estadísticas descriptivas.

3. Proceso ETL

El pipeline fue implementado en Python, puede ser ejecutado de forma local o como un notebook en Google Colab (ETL_Pipeline_WWTP_Soft_Sensor.ipynb), organizado en tres fases secuenciales — Extracción, Transformación y Carga — con logs detallados y generación automática de metadatos para trazabilidad completa. La implementación se apoya en las librerías pandas, NumPy, matplotlib y seaborn.

3.1 Fase de Extracción

La extracción consiste en la lectura del archivo CSV mediante pd.read_csv() y la generación de un reporte automático del estado de los datos crudos. Durante esta fase se verifica la dimensionalidad del dataset (105,409 × 31), se inspeccionan los tipos de datos por columna (confirmando que todos son numéricos sin tipos mixtos) y se contabilizan los 1,456 valores nulos nativos, identificando su distribución por variable. Esta inspección inicial es crítica para definir la estrategia de transformación.

3.2 Fase de Transformación

La transformación constituye el núcleo del pipeline e incluye 7 pasos secuenciales, cada uno documentado con métricas cuantitativas:

#	Paso	Descripción y justificación	Resultado
1	Estandarización de timestamps	Conversión de strings con formato MM/DD/YYYY HH:MM a objetos datetime de pandas mediante pd.to_datetime(format="mixed"). Ordenamiento cronológico del dataset para garantizar la coherencia de las operaciones basadas en ventanas temporales.	Serie ordenada, 0 fechas inválidas
2	Renombramiento de columnas	Transformación de los 31 nombres largos del SCADA a formato snake_case con unidades explícitas. Ejemplo: "Aeration Basin Eff Channel pH" → "effluent_ph". Esto mejora la legibilidad del código y facilita la referenciación programática.	31 columnas renombradas
3	Eliminación de columnas sin información	La variable do_basin6_mg_l presenta 99.9% de valores en cero durante los 366 días del período, indicando un sensor completamente fuera de servicio. Se elimina por no aportar información útil al análisis ni a futuros modelos.	−1 columna (do_basin6)
4	Interpolación de valores faltantes	Interpolación lineal con límite de 6 registros consecutivos (equivalente a 30 minutos). Los gaps mayores a 30 minutos se preservan como NaN para evitar la fabricación de datos en períodos donde el SCADA no registró información. La elección del método lineal se justifica por la continuidad física de las variables de proceso.	~1,400 valores interpolados
5	Detección y tratamiento de outliers	Aplicación de rangos físicos válidos definidos por conocimiento del dominio (ej: pH 4-10, DO 0-15 mg/L, temp efluente 0-40°C). Los valores fuera de rango se reemplazan con NaN. Los valores negativos en flujos de aire se corrigen con valor absoluto, ya que representan la convención de señal del SCADA para indicar dirección del flujo.	Consistencia física verificada
6	Validación de integridad temporal	Verificación de continuidad de la serie: se detectó un único gap de 1 hora 5 minutos correspondiente al cambio de horario (daylight saving time). Se identificaron y eliminaron 12 timestamps duplicados conservando el primer registro.	1 gap, 12 duplicados eliminados

7	Feature engineering	Creación de 24 características derivadas organizadas en 4 grupos: (a) temporales — hora, día de la semana, mes, indicador de fin de semana; (b) agregaciones — DO promedio entre 5 basins activos, flujo total de aire por basin; (c) eficiencia — porcentaje de remoción de amoniaco entre influente y efluente; (d) dinámica temporal — deltas, media rolling y desviación estándar rolling en ventana de 1 hora para amoniaco efluente, DO promedio, pH y SS.	24 nuevas columnas

3.3 Fase de Carga

La carga genera tres archivos de salida que constituyen los entregables de datos del proyecto:

1. **wwtp_aeration_processed.csv:** Dataset completo procesado en formato CSV estándar, directamente utilizable en cualquier herramienta de análisis o notebook de ciencia de datos.
2. **wwtp_aeration_processed.csv.gz:** Versión comprimida con gzip para almacenamiento eficiente y carga al repositorio compartido. La compresión reduce el tamaño en aproximadamente un 62%.
3. **data_statistics.csv:** Estadísticas descriptivas completas de todas las columnas (media, desviación estándar, percentiles, conteo de nulos, tipos de datos).

4. Resultados

4.1 Métricas del pipeline

Métrica	Valor
Registros extraídos (datos crudos)	105,409
Registros finales (datos procesados)	105,397
Columnas originales	31
Columnas finales (originales + características derivadas)	54
Completitud del dataset final	99.96%
Valores nulos tratados por interpolación	~1,400
Timestamps duplicados eliminados	12
Gaps temporales detectados	1 (1h 05min — cambio de horario)
Columnas eliminadas	1 (do_basin6 — sensor inactivo)
Tamaño CSV procesado	~71 MB
Tamaño comprimido gzip	~27 MB (−62%)
Período cubierto	Nov 2023 — Nov 2024 (366 días)
Frecuencia de muestreo	5 minutos (288 registros/día)

4.2 Estadísticas del dataset procesado

Las variables principales del proceso presentan los siguientes valores tras la aplicación del pipeline ETL, todos consistentes con los rangos operativos esperados para una planta WWTP de tratamiento biológico:

Variable	Media	Desv.Est.	Mín	Máx	Unidad	Interpretación
effluent_ammonium	0.54	1.49	0.00	12.00	mg/L	Bien tratado
effluent_ph	6.39	0.26	4.00	9.99	pH	Estable
effluent_ss	3,589	383	0	4,997	—	Señal SCADA
do_avg (5 basins)	2.49	0.66	0.26	8.97	mg/L	Rango nitrificación
influent_ammonium	43.18	16.41	0.00	150.00	mg/L	Carga típica
effluent_temp	20.88	4.11	0.00	26.69	°C	Normal
air_header_pressure	8.98	0.63	0.00	10.00	PSI	Estable
air_header_temp	170.5	17.2	109.0	217.9	°F	Aire comprimido
total_ras_flow	3,290	1,398	0	12,063	GPM	Variable

4.3 Hallazgos relevantes de la exploración

El proceso ETL y el análisis exploratorio revelaron patrones significativos para la comprensión del proceso y el futuro desarrollo de soft sensors:

4. **Eficiencia de nitrificación:** El DO promedio de 2.49 mg/L entre los 5 basins activos se encuentra dentro del rango óptimo para nitrificación (1.5-3.0 mg/L según Olsson et al., 2014),

y el amoniaco del efluente mantiene una media de 0.54 mg/L, indicando un proceso de remoción eficiente. Sin embargo, se observan picos hasta 12 mg/L que sugieren eventos transitorios de sobrecarga o disrupciones en la aireación.

5. **Estabilidad del pH:** La desviación estándar de 0.26 unidades alrededor de una media de 6.39 evidencia un proceso biológico bien tamponado y controlado, lo cual es indicativo de condiciones operativas saludables.
6. **Sensor inactivo Basin 6:** El DO del Basin 6 permanece en exactamente 0.00 mg/L durante la totalidad de los 366 días, lo que confirma un sensor completamente fuera de servicio. Este hallazgo ejemplifica el tipo de problema operativo que los soft sensors pueden ayudar a mitigar, proporcionando estimaciones virtuales cuando el sensor físico falla.
7. **Convención de señal SCADA:** Los valores negativos en los flujos de aire de las celdas 1-6 no representan flujos físicamente negativos, sino una convención del sistema SCADA para codificar la dirección del flujo. Este hallazgo fue determinado por conocimiento del dominio y corregido aplicando valor absoluto.
8. **Gap temporal único:** El único gap de 1 hora 5 minutos coincide con el cambio de horario (daylight saving time), lo cual confirma la alta confiabilidad del sistema de adquisición de datos durante el período analizado.
9. **Correlación clave:** La matriz de correlación generada en el notebook revela relaciones esperadas entre variables del proceso (correlación negativa entre DO y amoniaco efluente, correlación positiva entre flujo de aire y DO) que validan la coherencia física del dataset procesado.

5. Código en GitHub y datos en repositorio compartido

5.1 Estructura del repositorio

El código fuente, los datos y la documentación se organizan en un repositorio público de GitHub con la siguiente estructura:

```
wwtp-soft-sensor-etl/
│
├── config/                        Archivos de configuración: conexiones,
│   └── pipeline_config.yaml             parámetros del proyecto (rutas, rangos
│                                 válidos, mapeo de columnas, config de
│                                 transformación e ingeniería de features)
│
├── src/                           Código principal del ETL: scripts y
│   ├── __init__.py                    pipelines organizados por flujo
│   └── etl_pipeline.py                 Funciones extract(), transform(), load()
│
├── utils/                         Funciones auxiliares: conectores,
│   ├── __init__.py                    transformaciones, alertas, generadores
│   └── helpers.py                     load_config(), log_step(), validaciones
│
├── test/                          Pruebas: unitarias, integración, pruebas
│   ├── __init__.py                    del flujo completo del ETL
│   └── test_pipeline.py                9 tests (rangos, tipos, nulos, flujo E→T→L)
│
├── dwh_version/                       Versionamiento de esquemas del destino
│   └── schema_v1.0.0.yaml               de carga (columnas, tipos, unidades,
│                                 changelog)
│
├── data/
```

```
│   ├── raw/                        CSV original del SCADA
│   └── processed/                  CSV procesado + gzip
│
├── output/                         Resultados del pipeline
│   ├── data_statistics.csv         Estadísticas descriptivas
│   └── pipeline_metadata.json      Metadatos con trazabilidad
│
├── docs/                           Documentación académica
│   ├── Entregable_2.pdf            Problema, Indagación y Datos
│   └── Entregable_3.pdf            Solución Final
│
├── run.py                          Script de ejecución principal. Permite
│                                   correr flujos con argumentos desde CLI
│                                   Ej: python run.py --step=extract
│
├── requirements.txt                Dependencias Python
├── README.md                       Este archivo
└── ETL_Pipeline_WWTP_Soft_Sensor.ipynb   Notebook para Google Colab
```

5.2 Reproducibilidad

El notebook está diseñado para ejecutarse en Google Colab sin configuración adicional. El flujo de reproducción es: (1) clonar el repositorio o abrir el notebook en Colab, (2) subir el archivo CSV a Google Drive o directamente al entorno, (3) ajustar la variable FILEPATH si es necesario, y (4) ejecutar todas las celdas secuencialmente. El pipeline completo se ejecuta en aproximadamente 30 segundos y genera todos los archivos de salida automáticamente.

5.3 Datos en repositorio compartido

Los datos procesados hacen parte del repositorio GitHub, incluyendo: el dataset procesado comprimido (~27 MB), las estadísticas descriptivas, los metadatos del pipeline y una descripción del esquema de datos. Esto garantiza la accesibilidad y reproducibilidad a largo plazo, independientemente del estado del repositorio de GitHub.

Reflexiones finales

6.1 Sobre el proceso ETL como fundamento

El desarrollo de este proyecto confirma una realidad ampliamente documentada en la literatura de ciencia de datos industriales: la fase de preparación de datos consume la mayor parte del esfuerzo de cualquier proyecto analítico. En nuestro caso, el diseño, implementación y validación del pipeline ETL representó aproximadamente el 80% del tiempo total del proyecto. Esta proporción, lejos de ser una ineficiencia, refleja la criticidad de garantizar la integridad de los datos antes de cualquier análisis o modelado posterior.

Sin un ETL riguroso, los problemas de calidad detectados — sensor inactivo, valores negativos por convención de señal, gap temporal por cambio de horario — habrían contaminado cualquier modelo predictivo, produciendo resultados no confiables. Como señalan Haimi et al. (2013), la calidad de los datos es el factor limitante principal en el desempeño de los soft sensors en plantas WWTP.

6.2 Sobre los datos industriales reales

Trabajar con datos de un sistema SCADA real, en contraposición a datasets académicos preprocesados, aportó aprendizajes significativos:

- Los datos SCADA presentan problemas de calidad que no se encuentran en datasets de referencia como los de Kaggle o UCI: sensores que fallan silenciosamente (Basin 6 DO en cero sin ninguna alerta), convenciones de señal no documentadas (negativos en airflow) y artefactos temporales (gap por daylight saving time).
- La interpretación correcta de estos problemas requiere conocimiento del dominio industrial. Un científico de datos sin experiencia en procesos WWTP podría haber eliminado los valores negativos como errores o no haber identificado el sensor inactivo como tal.

6.3 Trabajo futuro

Con el dataset procesado (105,397 registros × 54 columnas, 99.96% completitud), las líneas de trabajo futuro incluyen:

- Desarrollo de modelos de soft sensor basados en LSTM, GRU o arquitecturas de ensemble para la predicción de nitrógeno amoniacal en el efluente, siguiendo las metodologías propuestas por Chen et al. (2026) y Sapmaz et al. (2022).
- Implementación de un sistema de detección de anomalías que utilice las estadísticas rolling (media y desviación estándar en ventana de 1 hora) generadas por el feature engineering del pipeline.
- Comparación del desempeño de soft sensors frente a sensores físicos, evaluando métricas de R^2, RMSE y MAPE, y analizando la capacidad de los modelos para detectar condiciones de fallo instrumental como el identificado en el Basin 6.
- Integración del pipeline con el sistema SCADA para ejecución periódica automatizada, habilitando la actualización continua del dataset y el reentrenamiento de modelos.

7. Referencias

[1] Chen, S., He, K., Huang, S., Yin, Q., Wong, Y., Ge, Y. & Hao, A. (2026). A novel soft sensor framework based on adaptive LSTM ensemble for robust water quality prediction in wastewater treatment plants. Water Science & Technology, 93(1). https://doi.org/10.2166/wst.2025.171

[2] Cecconi, F. & Rosso, D. (2021). Soft sensing for on-line fault detection of ammonium sensors in water resource recovery facilities. Environmental Science & Technology, 55, 10067-10076. https://doi.org/10.1021/acs.est.0c06111

[3] Haimi, H., Mulas, M., Corona, F. & Vahala, R. (2013). Data-derived soft-sensors for biological wastewater treatment plants: an overview. Environmental Modelling & Software, 47, 88-107. https://doi.org/10.1016/j.envsoft.2013.05.009

[4] Olsson, G. et al. (2014). Instrumentation, control and automation in wastewater — from London 1973 to Narbonne 2013. Water Science & Technology, 69, 1373-1385. https://doi.org/10.2166/wst.2014.057

[5] Sapmaz, A., Kurban, S., Dundar, A.G., Atac Yılmaz, D. & Kusoglu Kaya, G. (2022). Deep Learning Based Soft Sensor to Predict Total Suspended Solids of Refinery Water Treatment Plant Using Real Process Data. IFAC PapersOnLine, 55-33, 60-65.

[6] Yang, Y. et al. (2025). Integration of soft sensors and model predictive control for denitrification at a full-scale wastewater treatment plant. Journal of Water Process Engineering, 72, 107422.